Índice integrado de segurança: IBGE, SINESP e estabelecimentos

Projeto: BB-Dataton / Protege Empresa
Método: Mosler com agressão contextual adaptada ao projeto
Versão: `mosler-integrado-1.0`
Data do relatório: 28/10/2026
Situação: metodologia implementada e testada com dados sintéticos; pesos experimentais, ainda sem calibração por sinistros ou validação com a base completa.

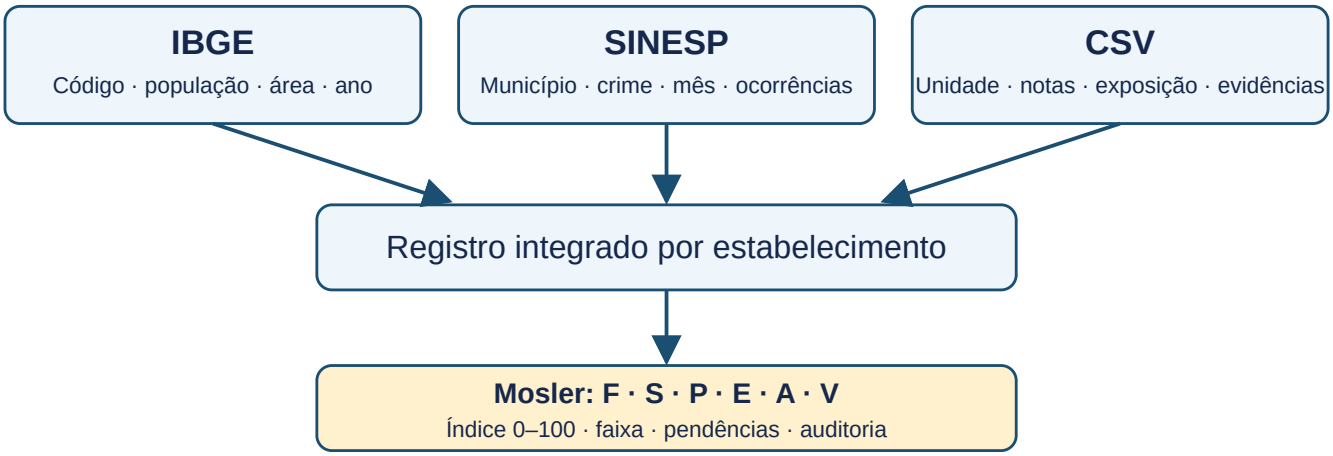
1. Resumo para apresentação

Estruturamos uma análise que cruza três conjuntos de dados em cada estabelecimento: o IBGE caracteriza e identifica o município; o SINESP descreve as ocorrências criminais publicadas; e o CSV descreve a atividade, os impactos e a vulnerabilidade da unidade empresarial. As três fontes compõem o mesmo registro analítico, vinculado pelo código IBGE de sete dígitos.

Adotamos o método Mosler para combinar consequências e condições de ocorrência do risco. O resultado é um índice de priorização por estabelecimento, de 0 a 100, acompanhado dos critérios utilizados, fontes, período e pendências. Duas empresas no mesmo município podem ter resultados diferentes por apresentarem impactos operacionais e vulnerabilidades diferentes.

Definimos pesos iniciais com base na pertinência conceitual das variáveis ao seguro empresarial. Esses pesos são hipóteses de projeto, documentadas e editáveis. Não foram estimados a partir dos 2.978 estabelecimentos, de sinistros ou de uma consulta a especialistas que não ocorreu. A implementação permite testar a sensibilidade dessas escolhas antes de utilizá-las operacionalmente.

2. O cruzamento das três fontes



As fontes têm papéis complementares, sem uma prioridade geral que permita substituir uma pela outra. A população não substitui ocorrências criminais; uma taxa municipal não substitui as características da empresa; o cadastro empresarial não permite inventar ocorrências ausentes.

Fonte	Campos utilizados	Papel no registro integrado
IBGE	Código municipal, nome, UF, população, área e anos de referência	Validar o território, normalizar as contagens pela população e contextualizar a densidade.
SINESP	Município/UF, natureza do crime, mês, ano, ocorrências e cobertura	Medir a exposição criminal contextual na janela comum de 12 meses.

Fonte	Campos utilizados	Papel no registro integrado
CSV	Empresa, imóvel/unidade, código municipal, exposição da atividade, notas Mosler e evidências	Caracterizar consequências, extensão operacional e vulnerabilidade específicas da unidade.

O cruzamento usa `many_to_one`: várias unidades podem compartilhar o mesmo município, mas cada chave empresa/unidade aparece uma única vez. A contagem de crimes é agregada por município/crime/mês **antes** de se associar às empresas; ela não é somada novamente a cada estabelecimento. A coorte municipal usada para suavização e percentis não muda quando o CSV contém mais empresas de uma mesma cidade.

O identificador final é `(empresa_id, imovel_id)`, preservando `codigo_ibge_municipio`. Não apresentamos um índice individual como se fosse um novo indicador oficial do município. Também não generalizamos a média das empresas do desafio para todos os estabelecimentos da cidade.

3. Preparação conjunta do contexto criminal

Para cada município e natureza selecionada, utilizamos os mesmos 12 meses civis encerrados e calculamos:

$$T_{m,c} = 100.000 \times \frac{N_{m,c,12m}}{Pop_m}$$

O numerador é do SINESP; o denominador é do IBGE. A taxa já é uma variável construída conjuntamente a partir das duas fontes. Dividir a taxa novamente pela população ou pela área duplicaria uma normalização sem justificativa.

Aplicamos suavização empírica Gamma-Poisson, com parâmetros estimados na coorte municipal com dados completos, para reduzir instabilidade de pequenas exposições. Depois transformamos as taxas suavizadas em percentis com postos médios para empates. O arquivo de auditoria conserva contagem, taxa bruta, taxa suavizada, contribuição da observação na suavização e percentil de cada crime.

O estimador usado tem `e_i=pop_i/100000`, `mu=sum(N_i)/sum(e_i)` e `tau²=max(0,sum((N_i-e_i*mu)²-e_i*mu)/sum(e_i²))`. Se `tau²>0`, utiliza `beta=mu/tau²` e taxa posterior `(N_i+mu*beta)/(e_i+beta)`. Essa escolha é uma hipótese de modelagem, não uma correção comprovada de subnotificação. Quando não há dispersão identificável em uma natureza selecionada, o contexto fica pendente; não criamos uma posição relativa fictícia.

A densidade `população/área` é apresentada como contexto. Não assumimos que cidades mais densas sejam necessariamente mais perigosas. Ela não recebe percentual direto no índice nem é usada como denominador do risco.

Exigimos 12 observações para cada natureza selecionada e população válida com ano conhecido, não posterior ao ano do período criminal. O mínimo inicial de 30 municípios completos é uma salvaguarda operacional, não prova de validade estatística. Uma alteração deliberada desse mínimo precisa ficar registrada.

4. Pesos que adotamos e por quê

4.1 Combinação das naturezas criminais

Natureza	Peso inicial	Justificativa de projeto	Limite da interpretação
Roubo de carga	**45%**	Aproximação contextual de exposição ligada à circulação de mercadorias e ao patrimônio empresarial.	Transporte de carga não é equivalente a roubo em loja ou escritório.
Roubo de veículos	**35%**	Contexto de mobilidade, ativos transportáveis e circulação operacional.	A pertinência depende do perfil da unidade; não implica que toda empresa possua frota.
Roubo seguido de morte — latrocínio	**15%**	Sinal contextual de violência associada ao roubo, sem dominar o componente patrimonial.	Não estima dano a pessoas no estabelecimento nem probabilidade de vitimização.

Natureza	Peso inicial	Justificativa de projeto	Limite da interpretação
Roubo a instituição financeira	**5%**	Participação residual, pela menor transferibilidade para empresas que não são instituições financeiras.	Para instituições financeiras, o perfil de pesos exige revisão específica.
Total	**100%**	Preferência metodológica inicial para um perfil empresarial genérico.	Sem comprovação de que esses valores sejam os melhores.

Se `Q_c` é o percentil municipal de cada natureza, o contexto é:

$$R_m = 0,45Q_{carga} + 0,35Q_{veículos} + 0,15Q_{latrocínio} + 0,05Q_{financeiras}$$

Os valores exatos 45/35/15/5 são uma **decisão normativa de modelagem**. A justificativa estabelece uma prioridade conceitual, mas não demonstra que 45% seja estatisticamente superior a 40% ou 50%. Não utilizamos CRITIC para estimar esses pesos nesta versão. O CRITIC anterior permanece apenas como modelo municipal comparativo, separado do novo Mosler integrado.

Antes de usar o contexto, é necessário confirmar no dicionário SINESP que as naturezas, a unidade de medida e a abrangência escolhidas são comparáveis e que não há sobreposição indevida. Vítimas, ocorrências, pesos e abrangências Estadual/PF/PRF não podem ser simplesmente somados. O importador estrito recusa chaves mensais duplicadas; o leiaute real ainda pode exigir adaptação explícita para selecionar ou agregar dimensões admissíveis.

4.2 Peso do contexto e da atividade no critério Agressão

Convertendo o contexto para a escala 1–5:

$$A_{municipal} = 1 + 4\ (\ R_m/100\ )$$

Com `X` representando a exposição da atividade avaliada no CSV, também em 1–5:

$$A_{contínuo} = 0,75A_{municipal} + 0,25X$$

Arredondamos `A_contínuo` para a nota inteira mais próxima, com metade para cima. Assim, 3,5 vira 4, mantendo a escala inteira 1–5 na fórmula Mosler.

Entrada de Agressão	Peso	Justificativa
Contexto municipal conjunto SINESP/IBGE	**75%**	Dar maior participação à medida criminal territorial publicada e auditável.
Exposição da atividade registrada no CSV	**25%**	Incorporar diferenças operacionais sem permitir que uma avaliação isolada substitua todo o contexto territorial.

Esses 75/25 também são hipóteses. O contexto municipal continua sendo uma proxy com limitações, mesmo com peso maior. O peso da exposição não é garantia de correção de um crime inadequado para a atividade. Perfis muito diferentes, como um escritório, uma transportadora e um banco, precisam de validação substantiva e eventualmente configurações próprias, versionadas.

Não atribuímos um “percentual global ao IBGE” porque população e código não são um escore independente de perigo. O IBGE participa de todas as taxas e da suavização. Os percentuais acima pesam indicadores comparáveis, e não arquivos brutos. O cruzamento conjunto das fontes não exige que cada uma receba um terço.

5. Critérios Mosler por estabelecimento

Critério	O que avaliamos	Origem e apoio documental	Âncoras da escala adotada
F — Função	Quanto um evento comprometeria a função principal da unidade.	CSV, operação descrita, patrimônio, estoque e continuidade.	1: impacto desprezível; 3: comprometimento parcial relevante; 5: paralisação da função essencial.

Critério	O que avaliamos	Origem e apoio documental	Âncoras da escala adotada
S — Substituição	Dificuldade de repor bens/recursos e restabelecer a função.	CSV e confirmação de reposição, fornecedores e alternativas.	1: reposição simples e acessível; 3: dificuldade intermediária; 5: substituição inviável ou extremamente difícil no horizonte analisado.
P — Profundidade	Gravidade das repercussões sobre pessoas, confiança e continuidade das relações.	Avaliação documentada, não inferida automaticamente de CNAE ou cidade.	1: repercussão mínima; 3: relevante; 5: muito grave e persistente.
E — Extensão	Alcance geográfico/operacional dos efeitos do evento.	CSV e declaração da abrangência da operação.	1: efeito individual; 2: local; 3: regional; 4: nacional; 5: internacional.
A — Agressão	Condições relativas de ocorrência no modelo contextual.	SINESP e IBGE cruzados com exposição da atividade do CSV.	Nota 1–5 calculada pela adaptação descrita acima. Não é probabilidade.
V — Vulnerabilidade	Fragilidade dos controles de proteção e de resposta da unidade.	Controles efetivamente declarados e verificados no CSV/questionário.	1: proteção e resposta consistentes; 3: proteção parcial; 5: fragilidade elevada, documentada.

F, S, P, E e V são notas qualitativas com avaliador, data e evidências. Os níveis 2 e 4 representam situações intermediárias entre as âncoras, com justificativa obrigatória no registro. A escala é uma operacionalização do projeto; não uma calibração ou escala universal oficial. Não consultamos especialistas para preencher essas notas nesta etapa.

O valor de um bem pode ajudar a discutir consequências e reposição, mas sozinho não define F ou S. Ter vários imóveis não comprova alcance nacional. Uma nota V não é calculada a partir de renda municipal ou reputação de um bairro. Informação desconhecida fica ausente; não recebe nota 1, 3 ou 5 por padrão.

A nota de exposição da atividade X segue a mesma orientação documentada: 1 para baixa exposição operacional externa de bens/valores; 3 para exposição intermediária; 5 para circulação/exposição frequente e relevante. Ela descreve condições de contato/exposição. V descreve fragilidade de controles, evitando registrar a mesma característica como se fossem duas evidências independentes.

6. Fórmula do índice

Preservamos a formulação usual de Mosler:

$$I = F \times S, \qquad D = P \times E, \qquad C = I + D$$

$$PR = A \times V, \qquad ER = C \times PR = \ (\ FS + PE\ )\ AV$$

PR é o produto operacional de duas notas ordinais, usualmente denominado “probabilidade” em apresentações do método. Aqui o identificamos como **produto Agressão–Vulnerabilidade** para não confundi-lo com uma probabilidade estatística entre 0 e 1.

Não acrescentamos pesos percentuais arbitrários aos seis critérios. Eles já participam por produtos e soma na estrutura Mosler. Os pesos escolhidos estão nas variáveis que alimentam A, e isso é identificado como adaptação. F, S, P, E e V vêm do perfil e das avaliações documentadas da unidade.

Com notas de 1 a 5, o menor ER possível é 2 e o maior é 1.250. A conversão é:

$$\text{Índice}_{0\text{–}100} = 100 \times \frac{ER - 2}{1250 - 2}$$

É uma transformação da escala, não um percentil nacional nem probabilidade de sinistro. Zero representa o menor escore possível no modelo, não ausência comprovada de risco. O produto de escalas ordinais é uma escolha de modelagem do método: não permite interpretar o dobro do escore como o dobro do risco real.

Faixas adotadas e compatibilidade com o formulário

ER Mosler	Faixa Mosler operacional	Faixa simplificada do projeto
2 a 250	Muito baixo	Baixo
251 a 500	Baixo	Baixo
501 a 750	Normal	Moderado
751 a 1.000	Alto	Alto
1.001 a 1.250	Muito alto	Muito alto

As faixas do projeto unem as duas primeiras classes. Não reutilizamos os cortes 25/50/75 do antigo índice de percentis para interpretar o Mosler. Guardamos as duas classificações para evitar confusão. Esses cortes são convenções operacionais; não demonstram frequência ou severidade esperada de sinistro.

7. Exemplo de cálculo para apresentar

Exemplo inteiramente ilustrativo; não descreve uma empresa da base real.

Admitindo que o cruzamento SINESP/IBGE produza percentis 80 para carga, 60 para veículos, 70 para latrocínio e 50 para instituições financeiras:

$$R_m = 0,45\ (\ 80\ )\ + 0,35\ (\ 60\ )\ + 0,15\ (\ 70\ )\ + 0,05\ (\ 50\ )\ = 70$$

Com exposição da atividade X=4, obtemos:

$$A_{municipal} = 1 + 4\ (\ 70/100\ )\ = 3,8$$

$$A_{contínuo} = 0,75\ (\ 3,8\ )\ + 0,25\ (\ 4\ )\ = 3,85 \Rightarrow A = 4$$

Para F=4, S=4, P=3, E=2 e V=3:

$$ER = \left[\ (\ 4 \times 4\ )\ +\ (\ 3 \times 2\ )\ \right] \times 4 \times 3 = 264$$

$$\text{Índice} = 100\ (\ 264 - 2\ )\ /1248 \approx 20,99$$

O resultado está na faixa Mosler **baixo**. O contexto municipal 70 e o índice final 20,99 medem objetos diferentes; não são dois cálculos concorrentes de probabilidade. O segundo incorpora consequências e vulnerabilidade da unidade.

No mesmo município, outra unidade com F=5, S=5, P=4, E=4 e V=5, mantendo A=4, teria ER=820, índice aproximadamente **65,54**, faixa **alto**. Isso demonstra como as três fontes se encontram numa avaliação individualizada.

8. Qualidade, ausências e sensibilidade

Não multiplicamos o índice por um “peso de confiança”. Isso faria informação incompleta diminuir artificialmente o risco. Completude, defasagem e qualidade são apresentadas separadamente.

- Sem município correspondente, população válida, meses completos ou uma nota obrigatória documentada, o resultado fica **PENDENTE_DADOS**, com índice nulo.
- Uma contagem zero explicitamente publicada permanece zero; mês ausente não recebe zero. A ausência de uma natureza não redistribui automaticamente seu peso.
- População muito antiga e série criminal defasada recebem avisos. A janela e os anos de referência permanecem visíveis. População do Censo 2022 não é apresentada como estimativa atual.
- Para cada peso de crime e cada peso de Agressão, calculamos cenários com variação relativa de **−20% e +20%**, um de cada vez. Os pesos são renormalizados apenas nesses cenários explicitamente identificados.
- Registramos mínimo e máximo encontrados, mudança de faixa e cada cenário. São cenários de sensibilidade, **não intervalo de confiança**, nem limites matemáticos para todas as combinações possíveis de pesos.
- O arredondamento de A pode produzir saltos de escore perto dos limiares. A auditoria guarda tanto A contínuo quanto A inteiro para permitir revisão.

Além dessa variação automatizada, a validação deverá avaliar perfis diferentes, seleção de crimes, escalas qualitativas e estabilidade temporal. Não basta a faixa ficar estável nos 12 cenários de pesos para considerar o modelo validado.

9. Situação dos dados e o que ainda não foi executado

O esquema SQLite e os importadores já existem. Nesta etapa implementamos o cruzamento e a avaliação Mosler em código, mas não recuperamos o CSV integral dos 2.978 estabelecimentos nem completamos o banco oficial SINESP/IBGE. As tentativas anteriores de coleta sofreram bloqueio de rede e desconexão. Não calculamos um ranking real desses estabelecimentos neste relatório.

O cadastro conhecido do projeto fornece informações financeiras/operacionais, mas não comprova que existam avaliações F, S, P, E, V, exposição da atividade, avaliador, data e evidências. Esses campos precisam ser preenchidos a partir de dados e declarações verificáveis. A implementação não os inventa.

A auditoria versionada na branch `codex/guia-atualizado-personalizacao` registra um arquivo SINESP 2025 com 31 categorias, sem "roubo em comércio". Essa informação foi consultada como registro de outra execução, não como nova inspeção do arquivo original nesta tarefa. Veículos, carga, bancos e latrocínio continuam sendo proxies contextuais; não equivalem à frequência de roubo empresarial de cada unidade.

Também faltam avaliação especializada das escalas, calibração, análise de subnotificação e comparação com desfechos externos. Mais complexidade no cruzamento não elimina essas limitações.

10. Reproduzir a implementação

Arquivos principais:

- `config/seguranca_mosler.json`: pesos, justificativas e versão.
- `seguranca/mosler.py`: cruzamento, fórmula, pendências e sensibilidade.
- `examples/estabelecimentos_mosler_modelo.csv`: somente cabeçalho do CSV; sem dados fictícios de produção.
- `tests/test_mosler_integrado.py`: testes com fixtures sintéticas isoladas.

O CSV consolidado utiliza:

```
empresa_id, imovel_id, codigo_ibge_municipio,
mosler_f, mosler_s, mosler_p, mosler_e, mosler_v,
exposicao_atividade_1a5, avaliador_mosler,
data_avaliacao_mosler, evidencias_mosler
```

As notas têm valores inteiros de 1 a 5. A data é ISO `AAAA-MM-DD`. Pode-se acrescentar `uf_real` para validar a compatibilidade entre UF e código municipal. Preservar os arquivos originais ao preparar esse CSV; avaliações e evidências adicionadas devem ser distinguíveis dos campos originalmente fornecidos.

Depois de importar os arquivos oficiais e preparar as avaliações documentadas:

```
cd /workspace/BB-Dataton
/workspace/.venvs/bb-dataton/bin/python -m seguranca avaliar-mosler \
  --estabelecimentos CAMINHO_DO_CSV_CONSOLIDADO \
  --fim AAAA-MM \
  --data-analise AAAA-MM-DD \
  --saida data/seguranca/mosler
```

Os parâmetros acima são marcadores, não arquivos supostamente baixados. O comando lê o SQLite em modo somente leitura e gera:

1. `indice_estabelecimentos_mosler.csv`, com uma linha por unidade;
2. `auditoria_mosler.json`, com critérios, contexto, pesos e cenários;
3. `cobertura_mosler.csv`, com calculados e pendentes por município do CSV;
4. `manifesto_mosler.json`, com versão, configuração e hashes das entradas/saídas.

Código de saída 0 significa que todas as unidades puderam ser calculadas; código 2 sinaliza pendências ou erro. Mesmo o código 0 não significa validação estatística ou aceitação contratual. O comando municipal anterior `gerar-indice` mantém o modelo CRITIC de comparação; os arquivos e significados são diferentes.

O novo resultado por unidade ainda precisa ser conectado ao fluxo do formulário que identifica ou avalia o estabelecimento. A consulta municipal existente continua sendo apenas contextual; não foi apresentada como se já entregasse um Mosler individual sem os campos necessários.

11. Roteiro curto para a equipe apresentar

> “Nós cruzamos os dados do IBGE, do SINESP e dos estabelecimentos em um registro único por unidade. O IBGE fornece o município e a população para normalizar as ocorrências, o SINESP descreve o contexto criminal e o CSV caracteriza impactos, exposição e vulnerabilidade da operação. Aplicamos Mosler para combinar esses elementos. Atribuímos pesos iniciais às naturezas criminais por pertinência ao contexto empresarial e documentamos a participação do contexto municipal e da atividade no critério Agressão. Esses pesos são hipóteses explícitas, sujeitas a análise de sensibilidade. O índice prioriza a análise de proteção; não é uma probabilidade de roubo, uma cotação ou uma validação atuarial. A execução com a base completa e a calibração externa ainda fazem parte da próxima etapa.”

12. Fontes e responsabilidade metodológica

- IBGE, API de localidades e agregado 4714 — Censo 2022.
- Ministério da Justiça, página oficial SINESP/VDE.
- Auditoria do projeto em outra branch: CONFIABILIDADE_SEGURANCA.md.
- Implementações públicas consultadas para referência da formulação Mosler: DanielDS5/mosler e nestorPons/mosler. São exemplos de software, não uma norma oficial ou validação científica dos pesos deste projeto. Não incorporamos seu código; a implementação local inclui validações próprias.
- Os pesos 45/35/15/5 e 75/25, a operacionalização das escalas, a normalização para 0–100 e a combinação das classes são decisões desta versão do projeto. Nenhuma dessas escolhas é atribuída ao IBGE, ao SINESP ou a uma validação empírica inexistente.