Índice integrado de segurança: IBGE, SINESP e estabelecimentos

Projeto: BB-Dataton / Protege Empresa
Método: Mosler com agressão contextual adaptada ao projeto
Versão: `mosler-integrado-1.0`
Data do relatório: 28/10/2026
Situação: metodologia implementada e testada com dados sintéticos; pesos experimentais, ainda sem calibração por sinistros ou validação com a base completa.

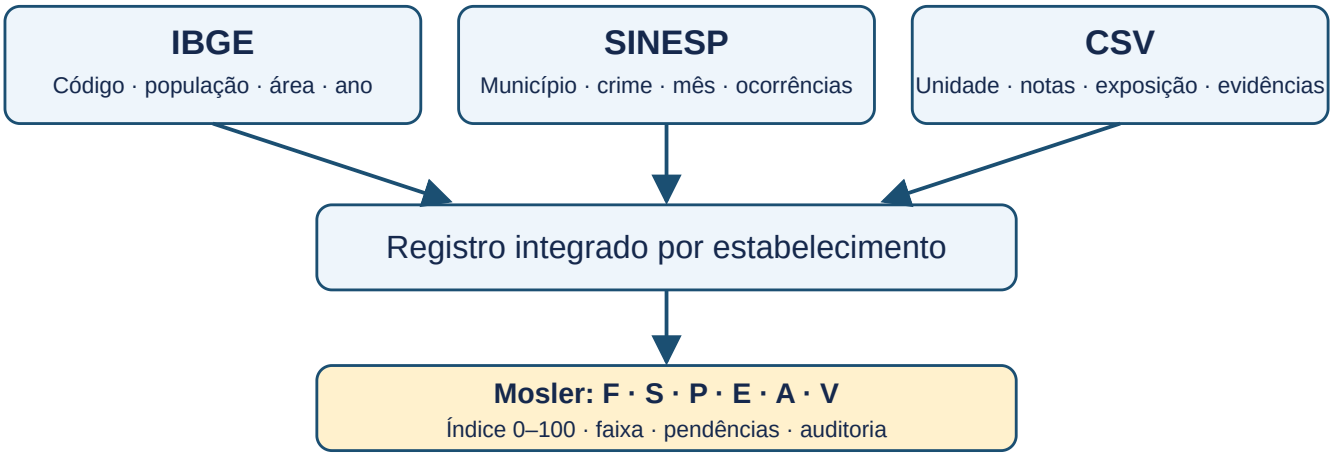
1. Resumo para apresentação

Estruturamos uma análise que cruza três conjuntos de dados em cada estabelecimento: o IBGE caracteriza e identifica o município; o SINESP descreve as ocorrências criminais publicadas; e o CSV descreve a atividade, os impactos e a vulnerabilidade da unidade empresarial. As três fontes compõem o mesmo registro analítico, vinculado pelo código IBGE de sete dígitos.

Adotamos o método Mosler para combinar consequências e condições de ocorrência do risco. O resultado é um índice de priorização por estabelecimento, de 0 a 100, acompanhado dos critérios utilizados, fontes, período e pendências. Duas empresas no mesmo município podem ter resultados diferentes por apresentarem impactos operacionais e vulnerabilidades diferentes.

Definimos pesos iniciais com base na pertinência conceitual das variáveis ao seguro empresarial. Esses pesos são hipóteses de projeto, documentadas e editáveis. Não foram estimados a partir dos 2.978 estabelecimentos, de sinistros ou de uma consulta a especialistas que não ocorreu. A implementação permite testar a sensibilidade dessas escolhas antes de utilizá-las operacionalmente.

2. O cruzamento das três fontes



As fontes têm papéis complementares, sem uma prioridade geral que permita substituir uma pela outra. A população não substitui ocorrências criminais; uma taxa municipal não substitui as características da empresa; o cadastro empresarial não permite inventar ocorrências ausentes.

Fonte	Campos utilizados	Papel no registro integrado
IBGE	Código municipal, nome, UF, população, área e anos de referência	Validar o território, normalizar as contagens pela população e contextualizar a densidade.
SINESP	Município/UF, natureza do crime, mês, ano, ocorrências e cobertura	Medir a exposição criminal contextual na janela comum de 12 meses.

Fonte	Campos utilizados	Papel no registro integrado
CSV	Empresa, imóvel/unidade, código municipal, exposição da atividade, notas Mosler e evidências	Caracterizar consequências, extensão operacional e vulnerabilidade específicas da unidade.

O cruzamento usa `many_to_one`: várias unidades podem compartilhar o mesmo município, mas cada chave empresa/unidade aparece uma única vez. A contagem de crimes é agregada por município/crime/mês **antes** de se associar às empresas; ela não é somada novamente a cada estabelecimento. A coorte municipal usada para suavização e percentis não muda quando o CSV contém mais empresas de uma mesma cidade.

O novo comando não executa o resolvedor hierárquico de fornecedores. Ele admite ocorrências com proveniência SINESP registrada, cruza essas observações com IBGE e CSV e mantém pendência se elas forem incompatíveis ou ausentes. Registros de SSPs presentes no mesmo SQLite continuam disponíveis para consulta separada, sem serem apresentados como se fossem observações SINESP.

O identificador final é `(empresa_id, imovel_id)`, preservando `codigo_ibge_municipio`. Não apresentamos um índice individual como se fosse um novo indicador oficial do município. Também não generalizamos a média das empresas do desafio para todos os estabelecimentos da cidade.

3. Preparação conjunta do contexto criminal

Para cada município e natureza selecionada, utilizamos os mesmos 12 meses civis encerrados e calculamos:

$$T_{m,c} = 100.000 \times \frac{N_{m,c,12m}}{Pop_m}$$

O numerador é do SINESP; o denominador é do IBGE. A taxa já é uma variável construída conjuntamente a partir das duas fontes. Dividir a taxa novamente pela população ou pela área duplicaria uma normalização sem justificativa.

Aplicamos suavização empírica Gamma-Poisson, com parâmetros estimados na coorte municipal com dados completos, para reduzir instabilidade de pequenas exposições. Depois transformamos as taxas suavizadas em percentis com postos médios para empates. O arquivo de auditoria conserva contagem, taxa bruta, taxa suavizada, contribuição da observação na suavização e percentil de cada crime.

O estimador usado tem `e_i=pop_i/100000`, `mu=sum(N_i)/sum(e_i)` e `tau²=max(0,sum((N_i-e_i*mu)²-e_i*mu)/sum(e_i²))`. Se `tau²>0`, utiliza `beta=mu/tau²` e taxa posterior `(N_i+mu*beta)/(e_i+beta)`. Essa escolha é uma hipótese de modelagem, não uma correção comprovada de subnotificação. Quando não há dispersão identificável em uma natureza selecionada, o contexto fica pendente; não criamos uma posição relativa fictícia.

A densidade `população/área` é apresentada como contexto. Não assumimos que cidades mais densas sejam necessariamente mais perigosas. Ela não recebe percentual direto no índice nem é usada como denominador do risco.

Exigimos 12 observações para cada natureza selecionada e população válida com ano conhecido, não posterior ao ano do período criminal. O mínimo inicial de 30 municípios completos é uma salvaguarda operacional, não prova de validade estatística. Uma alteração deliberada desse mínimo precisa ficar registrada.

4. Pesos que adotamos e por quê

4.1 Combinação das naturezas criminais

Natureza	Peso inicial	Justificativa de projeto	Limite da interpretação
Roubo de carga	**45%**	Aproximação contextual de exposição ligada à circulação de mercadorias e ao patrimônio empresarial.	Transporte de carga não é equivalente a roubo em loja ou escritório.
Roubo de veículos	**35%**	Contexto de mobilidade, ativos transportáveis e circulação operacional.	A pertinência depende do perfil da unidade; não implica que toda empresa possua frota.

Natureza	Peso inicial	Justificativa de projeto	Limite da interpretação
Roubo seguido de morte — latrocínio	**15%**	Sinal contextual de violência associada ao roubo, sem dominar o componente patrimonial.	Não estima dano a pessoas no estabelecimento nem probabilidade de vitimização.
Roubo a instituição financeira	**5%**	Participação residual, pela menor transferibilidade para empresas que não são instituições financeiras.	Para instituições financeiras, o perfil de pesos exige revisão específica.
Total	**100%**	Preferência metodológica inicial para um perfil empresarial genérico.	Sem comprovação de que esses valores sejam os melhores.

Se `Q_c` é o percentil municipal de cada natureza, o contexto é:

$$R_m = 0,45Q_{carga} + 0,35Q_{veículos} + 0,15Q_{latrocínio} + 0,05Q_{financeiras}$$

Os valores exatos 45/35/15/5 são uma **decisão normativa de modelagem**. A justificativa estabelece uma prioridade conceitual, mas não demonstra que 45% seja estatisticamente superior a 40% ou 50%. Não utilizamos CRITIC para estimar esses pesos nesta versão. O CRITIC anterior permanece apenas como modelo municipal comparativo, separado do novo Mosler integrado.

Antes de usar o contexto, é necessário confirmar no dicionário SINESP que as naturezas, a unidade de medida e a abrangência escolhidas são comparáveis e que não há sobreposição indevida. Vítimas, ocorrências, pesos e abrangências Estadual/PF/PRF não podem ser simplesmente somados. O importador estrito recusa chaves mensais duplicadas; o leiaute real ainda pode exigir adaptação explícita para selecionar ou agregar dimensões admissíveis.

4.2 Peso do contexto e da atividade no critério Agressão

Convertendo o contexto para a escala 1–5:

$$A_{municipal} = 1 + 4\,(\,R_m/100\,)$$

Com X representando a exposição da atividade avaliada no CSV, também em 1–5:

$$A_{contínuo} = 0,75A_{municipal} + 0,25X$$

Arredondamos `A_contínuo` para a nota inteira mais próxima, com metade para cima. Assim, 3,5 vira 4, mantendo a escala inteira 1–5 na fórmula Mosler.

Entrada de Agressão	Peso	Justificativa
Contexto municipal conjunto SINESP/IBGE	**75%**	Dar maior participação à medida criminal territorial publicada e auditável.
Exposição da atividade registrada no CSV	**25%**	Incorporar diferenças operacionais sem permitir que uma avaliação isolada substitua todo o contexto territorial.

Esses 75/25 também são hipóteses. O contexto municipal continua sendo uma proxy com limitações, mesmo com peso maior. O peso da exposição não é garantia de correção de um crime inadequado para a atividade. Perfis muito diferentes, como um escritório, uma transportadora e um banco, precisam de validação substantiva e eventualmente configurações próprias, versionadas.

Não atribuímos um “percentual global ao IBGE” porque população e código não são um escore independente de perigo. O IBGE participa de todas as taxas e da suavização. Os percentuais acima pesam indicadores comparáveis, e não arquivos brutos. O cruzamento conjunto das fontes não exige que cada uma receba um terço.

5. Critérios Mosler por estabelecimento

Critério	O que avaliamos	Origem e apoio documental	Âncoras da escala adotada
F — Função	Quanto um evento comprometeria a função principal da unidade.	CSV, operação descrita, patrimônio, estoque e continuidade.	1: impacto desprezível; 3: comprometimento parcial relevante; 5: paralisação da função essencial.
S — Substituição	Dificuldade de repor bens/recursos e restabelecer a função.	CSV e confirmação de reposição, fornecedores e alternativas.	1: reposição simples e acessível; 3: dificuldade intermediária; 5: substituição inviável ou extremamente difícil no horizonte analisado.
P — Profundidade	Gravidade das repercussões sobre pessoas, confiança e continuidade das relações.	Avaliação documentada, não inferida automaticamente de CNAE ou cidade.	1: repercussão mínima; 3: relevante; 5: muito grave e persistente.
E — Extensão	Alcance geográfico/operacional dos efeitos do evento.	CSV e declaração da abrangência da operação.	1: efeito individual; 2: local; 3: regional; 4: nacional; 5: internacional.
A — Agressão	Condições relativas de ocorrência no modelo contextual.	SINESP e IBGE cruzados com exposição da atividade do CSV.	Nota 1–5 calculada pela adaptação descrita acima. Não é probabilidade.
V — Vulnerabilidade	Fragilidade dos controles de proteção e de resposta da unidade.	Controles efetivamente declarados e verificados no CSV/questionário.	1: proteção e resposta consistentes; 3: proteção parcial; 5: fragilidade elevada, documentada.

F, S, P, E e V são notas qualitativas com avaliador, data e evidências. Os níveis 2 e 4 representam situações intermediárias entre as âncoras, com justificativa obrigatória no registro. A escala é uma operacionalização do projeto; não uma calibração ou escala universal oficial. Não consultamos especialistas para preencher essas notas nesta etapa.

O valor de um bem pode ajudar a discutir consequências e reposição, mas sozinho não define F ou S. Ter vários imóveis não comprova alcance nacional. Uma nota V não é calculada a partir de renda municipal ou reputação de um bairro. Informação desconhecida fica ausente; não recebe nota 1, 3 ou 5 por padrão.

A nota de exposição da atividade X segue a mesma orientação documentada: 1 para baixa exposição operacional externa de bens/valores; 3 para exposição intermediária; 5 para circulação/exposição frequente e relevante. Ela descreve condições de contato/exposição. V descreve fragilidade de controles, evitando registrar a mesma característica como se fossem duas evidências independentes.

6. Fórmula do índice

Preservamos a formulação usual de Mosler:

$$I = F \times S, \qquad D = P \times E, \qquad C = I + D$$

$$PR = A \times V, \qquad ER = C \times PR = \ (\ FS + PE\ )\ AV$$

PR é o produto operacional de duas notas ordinais, usualmente denominado “probabilidade” em apresentações do método. Aqui o identificamos como **produto Agressão–Vulnerabilidade** para não confundi-lo com uma probabilidade estatística entre 0 e 1.

Não acrescentamos pesos percentuais arbitrários aos seis critérios. Eles já participam por produtos e soma na estrutura Mosler. Os pesos escolhidos estão nas variáveis que alimentam A, e isso é identificado como adaptação. F, S, P, E e V vêm do perfil e das avaliações documentadas da unidade.

Com notas de 1 a 5, o menor ER possível é 2 e o maior é 1.250. A conversão é:

$$\text{Índice}_{0\text{–}100} = 100 \times \frac{ER - 2}{1250 - 2}$$

É uma transformação da escala, não um percentil nacional nem probabilidade de sinistro. Zero representa o menor escore possível no modelo, não ausência comprovada de risco. O produto de escalas ordinais é uma escolha de modelagem do método: não permite interpretar o dobro do escore como o dobro do risco real.

Faixas adotadas e compatibilidade com o formulário

ER Mosler	Faixa Mosler operacional	Faixa simplificada do projeto
2 a 250	Muito baixo	Baixo
251 a 500	Baixo	Baixo
501 a 750	Normal	Moderado
751 a 1.000	Alto	Alto
1.001 a 1.250	Muito alto	Muito alto

As faixas do projeto unem as duas primeiras classes. Não reutilizamos os cortes 25/50/75 do antigo índice de percentis para interpretar o Mosler. Guardamos as duas classificações para evitar confusão. Esses cortes são convenções operacionais; não demonstram frequência ou severidade esperada de sinistro.

7. Exemplo de cálculo para apresentar

Exemplo inteiramente ilustrativo; não descreve uma empresa da base real.

Admitindo que o cruzamento SINESP/IBGE produza percentis 80 para carga, 60 para veículos, 70 para latrocínio e 50 para instituições financeiras:

$$R_m = 0,45\ (\ 80\ )\ + 0,35\ (\ 60\ )\ + 0,15\ (\ 70\ )\ + 0,05\ (\ 50\ )\ = 70$$

Com exposição da atividade `X=4`, obtemos:

$$A_{municipal} = 1 + 4\ (\ 70/100\ )\ = 3,8$$

$$A_{contínuo} = 0,75\ (\ 3,8\ )\ + 0,25\ (\ 4\ )\ = 3,85 \Rightarrow A = 4$$

Para `F=4`, `S=4`, `P=3`, `E=2` e `V=3`:

$$ER = \left[\ (\ 4 \times 4\ )\ +\ (\ 3 \times 2\ )\ \right] \times 4 \times 3 = 264$$

$$\text{Índice} = 100\ (\ 264 - 2\ )\ /1248 \approx 20,99$$

O resultado está na faixa Mosler **baixo**. O contexto municipal 70 e o índice final 20,99 medem objetos diferentes; não são dois cálculos concorrentes de probabilidade. O segundo incorpora consequências e vulnerabilidade da unidade.

No mesmo município, outra unidade com `F=5`, `S=5`, `P=4`, `E=4` e `V=5`, mantendo `A=4`, teria `ER=820`, índice aproximadamente **65,54**, faixa **alto**. Isso demonstra como as três fontes se encontram numa avaliação individualizada.

8. Qualidade, ausências e sensibilidade

Não multiplicamos o índice por um “peso de confiança”. Isso faria informação incompleta diminuir artificialmente o risco. Completude, defasagem e qualidade são apresentadas separadamente.

- Sem município correspondente, população válida, meses completos ou uma nota obrigatória documentada, o resultado fica **PENDENTE_DADOS**, com índice nulo.
- Uma contagem zero explicitamente publicada permanece zero; mês ausente não recebe zero. A ausência de uma natureza não redistribui automaticamente seu peso.
- População muito antiga e série criminal defasada recebem avisos. A janela e os anos de referência permanecem visíveis. População do Censo 2022 não é apresentada como estimativa atual.
- Para cada peso de crime e cada peso de Agressão, calculamos cenários com variação relativa de **−20% e +20%**, um de cada vez. Os pesos são renormalizados apenas nesses cenários explicitamente identificados.

- Registramos mínimo e máximo encontrados, mudança de faixa e cada cenário. São cenários de sensibilidade, **não intervalo de confiança**, nem limites matemáticos para todas as combinações possíveis de pesos.
- O arredondamento de A pode produzir saltos de escore perto dos limiares. A auditoria guarda tanto A contínuo quanto A inteiro para permitir revisão.

Além dessa variação automatizada, a validação deverá avaliar perfis diferentes, seleção de crimes, escalas qualitativas e estabilidade temporal. Não basta a faixa ficar estável nos 12 cenários de pesos para considerar o modelo validado.

9. Situação dos dados e o que ainda não foi executado

Durante a integração desta alteração, recuperamos dois commits novos da branch remota, com relatórios de coleta e auditoria executadas em outro ambiente. Segundo essas evidências versionadas, o IBGE e o VDE 2025 foram baixados e o pacote de 2.978 estabelecimentos foi conferido. A causa remanescente para a indisponibilidade do índice não é simplesmente a antiga falha de download.

Evidência versionada da execução anterior	Resultado documentado
Cadastro IBGE	5.571 localidades; população estimada 2025, área censitária 2022 quando disponível.
Estabelecimentos do desafio	2.978 unidades em dez municípios/UFs, todas com código IBGE correspondente.
SINESP VDE 2025	832.302 linhas; recorte de roubos com 69.510 registros preservados.
Ocorrências de carga, veículos e instituição financeira no VDE inspecionado	Município não informado; contagens estaduais não podem ser rateadas artificialmente entre municípios.
Latrocínio no VDE inspecionado	Contagem de vítimas, sem a unidade de ocorrências exigida.
Fontes estaduais complementares da etapa anterior	Algum indicador para 527 unidades e roubo em comércio para 302; não constituem observações SINESP.

Esses números são os resultados dos relatórios incorporados ao Git, não uma nova execução da base real nesta instância. Os arquivos brutos e o pacote completo continuam fora do versionamento e não estavam disponíveis neste workspace. Nesta tarefa, implementamos e testamos o cruzamento Mosler; não recalculamos um ranking real dos 2.978 estabelecimentos.

O cadastro conhecido do projeto fornece informações financeiras/operacionais, mas não comprova que existam avaliações F, S, P, E, V, exposição da atividade, avaliador, data e evidências. Esses campos precisam ser preenchidos a partir de dados e declarações verificáveis. A implementação não os inventa.

A validação real incorporada também registra 31 categorias no VDE, sem “roubo em comércio”. Além da distinção conceitual, a edição inspecionada não satisfaz a granularidade/unidade dos quatro critérios propostos. Atribuir pesos ou aplicar Mosler não corrige essa incompatibilidade. O novo modelo conserva a pendência e não usa a hierarquia antiga para preencher os critérios com outra definição. Veículos, carga, bancos e latrocínio, quando houver dados municipais admissíveis, serão proxies contextuais, não frequência individual de roubo empresarial.

Também faltam avaliação especializada das escalas, calibração, análise de subnotificação e comparação com desfechos externos. Mais complexidade no cruzamento não elimina essas limitações.

10. Reproduzir a implementação

Arquivos principais:

- `config/seguranca_mosler.json`: pesos, justificativas e versão.
- `seguranca/mosler.py`: cruzamento, fórmula, pendências e sensibilidade.
- `examples/estabelecimentos_mosler_modelo.csv`: somente cabeçalho do CSV; sem dados fictícios de produção.
- `tests/test_mosler_integrado.py`: testes com fixtures sintéticas isoladas.

O CSV consolidado utiliza:

```
empresa_id, imovel_id, codigo_ibge_municipio,
mosler_f, mosler_s, mosler_p, mosler_e, mosler_v,
exposicao_atividade_1a5, avaliador_mosler,
data_avaliacao_mosler, evidencias_mosler
```

As notas têm valores inteiros de 1 a 5. A data é ISO `AAAA-MM-DD`. Pode-se acrescentar `uf_real` para validar a compatibilidade entre UF e código municipal. Preservar os arquivos originais ao preparar esse CSV; avaliações e evidências adicionadas devem ser distinguíveis dos campos originalmente fornecidos.

Depois de importar os arquivos oficiais e preparar as avaliações documentadas:

```
cd /workspace/BB-Dataton
/workspace/.venvs/bb-dataton/bin/python -m seguranca avaliar-mosler \
  --estabelecimentos CAMINHO_DO_CSV_CONSOLIDADO \
  --fim AAAA-MM \
  --data-analise AAAA-MM-DD \
  --saida data/seguranca/mosler
```

Os parâmetros acima são marcadores, não arquivos supostamente baixados. O comando lê o SQLite em modo somente leitura e gera:

1. `indice_estabelecimentos_mosler.csv`, com uma linha por unidade;
2. `auditoria_mosler.json`, com critérios, contexto, pesos e cenários;
3. `cobertura_mosler.csv`, com calculados e pendentes por município do CSV;
4. `manifesto_mosler.json`, com versão, configuração e hashes das entradas/saídas.

Código de saída 0 significa que todas as unidades puderam ser calculadas; código 2 sinaliza pendências ou erro. Mesmo o código 0 não significa validação estatística ou aceitação contratual. O comando municipal anterior `gerar-indice` mantém o modelo CRITIC de comparação; os arquivos e significados são diferentes.

O novo resultado por unidade ainda precisa ser conectado ao fluxo do formulário que identifica ou avalia o estabelecimento. A consulta municipal existente continua sendo apenas contextual; não foi apresentada como se já entregasse um Mosler individual sem os campos necessários.

11. Roteiro curto para a equipe apresentar

> “Nós cruzamos os dados do IBGE, do SINESP e dos estabelecimentos em um registro único por unidade. O IBGE fornece o município e a população para normalizar as ocorrências, o SINESP descreve o contexto criminal e o CSV caracteriza impactos, exposição e vulnerabilidade da operação. Aplicamos Mosler para combinar esses elementos. Atribuímos pesos iniciais às naturezas criminais por pertinência ao contexto empresarial e documentamos a participação do contexto municipal e da atividade no critério Agressão. Esses pesos são hipóteses explícitas, sujeitas a análise de sensibilidade. O índice prioriza a análise de proteção; não é uma probabilidade de roubo, uma cotação ou uma validação atuarial. A execução com a base completa e a calibração externa ainda fazem parte da próxima etapa.”

12. Fontes e responsabilidade metodológica

- IBGE, API de localidades e agregado 4714 — Censo 2022.
- Ministério da Justiça, página oficial SINESP/VDE.
- Auditoria do projeto em outra branch: CONFIABILIDADE_SEGURANCA.md.
- Evidências posteriores incorporadas nesta branch: VALIDACAO_SEGURANCA_2025.md e HIERARQUIA_FONTES.md, esta última preservada como histórico da política anterior, sem aplicação automática no Mosler integrado.
- Implementações públicas consultadas para referência da formulação Mosler: DanielDS5/mosler e nestorPons/mosler. São exemplos de software, não uma norma oficial ou validação científica dos pesos deste projeto. Não incorporamos seu código; a implementação local inclui validações próprias.
- Os pesos 45/35/15/5 e 75/25, a operacionalização das escalas, a normalização para 0–100 e a combinação das classes são decisões desta versão do projeto. Nenhuma dessas escolhas é atribuída ao IBGE, ao SINESP ou a uma validação empírica inexistente.